
Weather-Based Activity Recommendation Engine

Michał Liberacki 198135
Szymon Mielniczak 197956

Cel projektu i Architektura danych

- **Cel:** Stworzenie systemu rekomendacji aktywności na podstawie dynamicznych parametrów pogodowych.
- **Ingestia danych:** Pobieranie paczek danych z zewnętrznego REST API (stacje: GDN_01, GDN_02, SOP_01, GBA_01).
- **Warstwa Raw:** Zapis surowych plików JSON w usłudze Amazon S3 w celu zachowania pełnego audytu danych.
- **Warstwa Curated:** Transformacja do zoptymalizowanego formatu Parquet i zapis w docelowych folderach S3.

Objects (5)

Objects are the fundamental entities stored in Amazon S3. You can use [Amazon S3 inventory](#) to get a list of all objects in your bucket. For others to access your objects, you'll need to explicitly grant them permissions. [Learn more](#)

☐	Name	Type	Last modified	Size	Storage class
☐	analytical_output/	Folder	-	-	-
☐	curated_data_\$folder\$	-	June 12, 2026, 22:55:33 (UTC+02:00)	0 B	Standard
☐	curated_data/	Folder	-	-	-
☐	e-5191H0ET4Z6BB56L8788NMVKP/	Folder	-	-	-
☐	raw_data/	Folder	-	-	-

Metoda analityczna

- **Algorytm:** Rozproszony klasyfikator Random Forest z biblioteki *PySpark MLlib*.
- **Budowa potoku ML (Pipeline):**
 - *StringIndexer* - mapowanie tekstowych etykiet aktywności na indeksy numeryczne.
 - *VectorAssembler* - agregacja cech pogodowych takich jak: Temperatura, Wiatr, Opady, Zachmurzenie w jeden wektor wejściowy.
- Podział danych na część treningową i testową w celu ewaluacji modelu.

```
curated_s3_path = "s3://michal-super-bucket-6767/curated_data/weather_labeled"
df_input = spark.read.parquet(curated_s3_path)
train_data, test_data = df_input.randomSplit([0.7, 0.3], seed=42)

indexer = StringIndexer(inputCol="activity", outputCol="label", handleInvalid="skip")
assembler = VectorAssembler(inputCols=["temperature", "wind_speed", "rain_mm", "cloud_cover"], outputCol="features")
rf = RandomForestClassifier(labelCol="label", featuresCol="features", numTrees=20)

pipeline = Pipeline(stages=[indexer, assembler, rf])
trained_model = pipeline.fit(train_data)
```

Wyniki - Rozkład danych i Metryki


TABELA: CZESTOTLIWOSC WYSTĘPOWANIA ETYKIET W ZBIORZE:

activity	count
Muzeum	3384
Jazda na rowerze	1020
Kitesurfing	500
Spacer	273
Basen kryty	23

- **Hiperparametry modelu:** 20 drzew w lesie, maksymalna głębokość drzewa równa 5.
- **Skuteczność:** Model osiągnął dokładność Accuracy = 98.77%.
- Zbiór uczący cechował się zróżnicowanym rozkładem klas, z dominacją aktywności np. kulturalnych lub "na świeżym powietrzu" przy konkretnych warunkach np. muzeum dla dni deszczowych.

Wyniki - Analiza ważności cech

WYKRES WAZNOSCI PARAMETROW POGODOWYCH W MODELU



- Analiza komponentu *featureImportances* wykazała, które czynniki atmosferyczne mają kluczowy wpływ na decyzje modelu.
- **Główny czynnik:** Opady atmosferyczne determinują aż 75% decyzji systemu - kluczowy podział na aktywności pod dachem i na wolnym powietrzu.
- **Czynniki drugorzędne:** Prędkość wiatru 15.3% oraz temperatura 9.3% precyzują wybór konkretnych sportów np. kitesurfing przy silnym wietrze. Zachmurzenie ma marginalny wpływ - 0.4%.

Wnioski końcowe

- **Architektura Lakehouse:** Podział na warstwy (Raw -> Curated) w chmurze S3 dobrze się sprawdził - zapewnia szybki dostęp do czystych danych.
- **Stabilność algorytmu:** Random Forest okazał się dobrym wyborem - wysoka dokładność przy krótkim czasie trenowania.
- **Zastosowanie:** System z powodzeniem może zostać wdrożony jako usługa dla portali turystycznych lub aplikacji pogodowych.

A person wearing a dark blue quilted jacket, blue jeans, and bright yellow rubber boots is captured mid-splash in a shallow body of water. The person's arms are outstretched to the sides, and a large, dynamic splash of water surrounds their lower legs and boots. The background is a soft-focus view of green trees and foliage. The overall mood is energetic and joyful.

**DZIĘKUJEMY
ZA UWAGĘ**