

Sprawozdanie z Zadania Projektowego

Project 25: Weather-Based Activity Recommendation Engine

Michał Liberacki Nr albumu: 198135
Szymon Mielniczak Nr albumu: 197956

20 czerwca 2026

Spis treści

1	Cel Projektu i Architektura	2
1.1	Potok Danych (Data Pipeline)	2
2	Metoda Analityczna i Ewaluacja	2
2.1	Generowanie i Augmentacja Danych	2
2.2	Rozkład danych uczących	2
2.3	Metryki skuteczności	3
3	Analiza Ważności Cech (Feature Importance)	3
4	Wnioski i Ograniczenia	3

1 Cel Projektu i Architektura

Celem projektu było zaprojektowanie i wdrożenie autonomicznego systemu rekomendacji aktywności rekreacyjnych na podstawie aktualnych warunków pogodowych. System wykorzystuje przetwarzanie rozproszone (PySpark) oraz algorytmy uczenia maszynowego (Random Forest).

1.1 Potok Danych (Data Pipeline)

Zgodnie z wytycznymi, system implementuje architekturę warstwową:

- **Ingestia:** Pobieranie danych z zewnętrznego API pogodowego (REST API).
- **Warstwa Raw (S3):** Zapis surowych plików JSON w celu zachowania pełnego audytu danych.
- **Warstwa Curated (S3):** Czyszczenie, rzutowanie typów i transformacja do zoptymalizowanego formatu Parquet za pomocą klastra AWS EMR.


2 Metoda Analityczna i Ewaluacja

2.1 Generowanie i Augmentacja Danych

W początkowej fazie analizy zaobserwowano, że surowe dane z API, ograniczone do okresu wiosenno-letniego, nie zawierały przypadków ekstremalnych (np. ujemnych temperatur lub fal upałów). W celu zapewnienia odporności modelu na wszelkie warunki atmosferyczne, zastosowano technikę *data augmentation*. Do zbioru uczącego wstrzyknięto syntetyczne rekordy reprezentujące scenariusze brzegowe (morsowanie, plażowanie, ekstremalne ulewy). Dzięki temu system poprawnie reaguje na zmienne pogodowe niezależnie od pory roku.

2.2 Rozkład danych uczących

Dane wejściowe charakteryzują się zróżnicowanym rozkładem etykiet, z dominacją aktywności typu "indoor" podczas niesprzyjających warunków atmosferycznych.



Rysunek 1: Wizualizacja rozkładu etykiet w zbiorze uczącym


2.3 Metryki skuteczności

Jako silnik decyzyjny zastosowano klasyfikator Random Forest z biblioteki PySpark MLlib (20 drzew, głębokość 5). Model osiągnął znakomite wyniki:

- **Całkowita dokładność (Accuracy):** 98.93%
- **Błąd klasyfikacji (Error Rate):** 1.07%

3 Analiza Ważności Cech (Feature Importance)

W celu interpretacji decyzji podejmowanych przez model, przeprowadzono analizę wpływu poszczególnych zmiennych atmosferycznych.



Rysunek 2: Wpływ parametrów pogodowych na decyzje modelu

4 Wnioski i Ograniczenia

1. **Automatyzacja:** Zbudowany pipeline skutecznie integruje pobieranie danych, transformację i augmentację syntetyczną w chmurze obliczeniowej.
2. **Skuteczność algorytmu:** Random Forest, wspomagany przez inżynierię cech, okazał się wysoce stabilny i odporny na specyfikę danych meteorologicznych.
3. **Ograniczenia środowiskowe:** Architektura została zaprojektowana w oparciu o przetwarzanie wsadowe (batch). Dalszy rozwój systemu zakłada migrację do przetwarzania strumieniowego w celu obsługi zdarzeń w czasie rzeczywistym.