

Sprawozdanie z Zadania Projektowego

Project 25: Weather-Based Activity Recommendation Engine

Michał Liberacki Nr albumu: 198135
Szymon Mielniczak Nr albumu: 197956

20 czerwca 2026

Spis treści

1	Cel Projektu i Architektura	2
1.1	Potok Danych (Data Pipeline)	2
2	Metoda Analityczna i Ewaluacja	2
2.1	Rozkład danych uczących	2
2.2	Metryki skuteczności	2
3	Analiza Ważności Cech (Feature Importance)	3
4	Wnioski i Ograniczenia	3

1 Cel Projektu i Architektura

Celem projektu było zaprojektowanie i wdrożenie autonomicznego systemu rekomendacji aktywności rekreacyjnych na podstawie aktualnych warunków pogodowych. System wykorzystuje przetwarzanie rozproszone (PySpark) oraz algorytmy uczenia maszynowego (Random Forest).

1.1 Potok Danych (Data Pipeline)

Zgodnie z wytycznymi, system implementuje architekturę warstwową:


- **Ingestia:** Pobieranie danych z zewnętrznego API pogodowego (REST API).
- **Warstwa Raw (S3):** Zapis surowych plików JSON w celu zachowania pełnego audytu danych.
- **Warstwa Curated (S3):** Czyszczenie, rzutowanie typów i transformacja do zoptymalizowanego formatu Parquet za pomocą klastra AWS EMR.

2 Metoda Analityczna i Ewaluacja

Jako silnik decyzyjny zastosowano klasyfikator Random Forest z biblioteki PySpark MLlib. Algorytm zdefiniowano na 20 drzewach decyzyjnych o maksymalnej głębokości równej 5, co zapobiega zjawisku przeuczenia (overfitting).

2.1 Rozkład danych uczących

Dane wejściowe charakteryzują się zróżnicowanym rozkładem etykiet, z dominacją aktywności typu "indoor" podczas niesprzyjających warunków atmosferycznych.



Rysunek 1: Wizualizacja rozkładu etykiet w zbiorze uczącym

2.2 Metryki skuteczności


Model osiągnął znakomite wyniki na zbiorze testowym, poprawnie mapując reguły pogodowe:

- **Całkowita dokładność (Accuracy):** 98.93%

- Błąd klasyfikacji (Error Rate): 1.07%

3 Analiza Ważności Cech (Feature Importance)

W celu interpretacji decyzji podejmowanych przez model, przeprowadzono analizę wpływu poszczególnych zmiennych atmosferycznych. Wyniki wskazują, że opady atmosferyczne pełnią rolę kluczowego katalizatora (decydującego o podziale na aktywności pod dachem oraz na zewnątrz).



Rysunek 2: Wpływ parametrów pogodowych na decyzje modelu

4 Wnioski i Ograniczenia

Na podstawie przeprowadzonych prac analitycznych wyciągnięto następujące wnioski:

1. **Automatyzacja:** Zbudowany pipeline skutecznie łączy pobieranie danych, ich transformację w chmurze obliczeniowej oraz serwowanie rekomendacji w czasie niemal rzeczywistym.
2. **Skuteczność algorytmu:** Random Forest okazał się wysoce stabilnym algorytmem dla danych numerycznych, osiągając ponad 98% skuteczności przy krótkim czasie uczenia.
3. **Ograniczenia środowiskowe:** Architektura została zaprojektowana w oparciu o przetwarzanie wsadowe (batch processing) ze względu na optymalizację kosztów w środowisku studenckim. Rozbudowa systemu mogłaby obejmować migrację do przetwarzania strumieniowego.